P2 -- Overview

Automatic Generation of Python Programming Quiz Questions and Distractors Using IndoT5 with LoRA for Indonesian Educational Content

1. Penjelasan Awal project

Penelitian ini mengembangkan sistem *Automatic Question Generation* (AQG) berbasis model seq2seq untuk menghasilkan soal kuis pemrograman Python secara otomatis, lengkap dengan satu jawaban benar dan 3–4 distraktor yang pedagogis. Sistem ini dirancang khusus untuk mendukung pembuatan konten evaluasi pada platform pembelajaran coding adaptif berbahasa Indonesia yang menargetkan siswa tingkat menengah.

Model utama yang digunakan adalah **IndoT5** (**IndoNanoT5-base** variant yang dilatih pra secara eksklusif pada korpus monolingual Indonesia, misalnya CulturaX). Pemilihan IndoT5 didasarkan pada benchmark IndoNLG, di mana model ini mencapai skor rata-rata **71,89** — lebih tinggi dibandingkan IndoBART (68,18) — serta lebih efisien dan stabil untuk tugas generative sequence-to-sequence dengan lebih sedikit halusinasi pada teks bahasa Indonesia. Model ini dilengkapi dengan **mT5-base** sebagai fallback multilingual untuk meningkatkan generalisasi pada code-mixed text.

Fine-tuning dilakukan dengan teknik **LoRA** (Low-Rank Adaptation) pada rank = 8, alpha = 16, dropout = 0.1, learning rate = 2×10^{-4}, batch size = 8, dan maksimal 6 epoch dengan early stopping berdasarkan validation loss. Teknik prompt engineering digunakan untuk mengontrol tingkat kesulitan dan jenis soal (MCQ atau Code Completion).

Alur sistem secara keseluruhan dapat digambarkan sebagai berikut: Materi Python Basics (Markdown/YAML) → Preprocessing & Prompt Construction → **IndoT5 + LoRA** (Question & Distractor Generation) → Filtering & Semantic Validation → Output Soal Siap Pakai.

Tujuan utama adalah mengatasi keterbatasan pembuatan soal manual yang memakan waktu dan kurang variatif. Evaluasi akan menggunakan metrik otomatis (BLEU-4, ROUGE-L, BERTScore) dan human evaluation (relevance, clarity, difficulty calibration, pedagogical value).

Proyek ini memberikan kontribusi teknis bagi pengembangan konten edukasi berbahasa Indonesia sekaligus memperkaya literatur NLP untuk pendidikan pemrograman di negara berkembang.

2. Permasalahan (Masalah yang Ingin Diselesaikan & Mengapa Penting)

Masalah Utama yang Ingin Diselesaikan

Penelitian ini menargetkan tiga permasalahan utama dalam pembuatan konten evaluasi untuk platform pembelajaran coding adaptif berbahasa Indonesia:

1. Kurangnya variasi dan skalabilitas soal kuis. Saat ini, soal kuis pemrograman Python masih dibuat secara manual, sehingga jumlah soal per sesi sangat terbatas (rata-rata hanya 10–15 soal), dan siswa mudah menghafal pola jawaban setelah beberapa kali percobaan ulang.
2. Beban kerja content creation yang tinggi. Pembuatan satu set 20 soal MCQ berkualitas (termasuk distraktor yang masuk akal dan mendidik) memerlukan waktu 4–6 jam per modul (Raccoon Gang, 2025; Optivly, 2025). Untuk satu course Python Basics (8 modul), total waktu mencapai 32–48 jam kerja manual.
3. Kurangnya personalisasi assessment. Sistem saat ini tidak mampu menghasilkan soal baru secara dinamis yang disesuaikan dengan tingkat kesulitan dan kesalahan umum siswa.

Mengapa Masalah Ini Penting?

Dalam platform pembelajaran coding adaptif, kuis merupakan komponen inti untuk mengukur pemahaman dan memicu review prerequisite. Tanpa variasi soal yang memadai, efektivitas pembelajaran akan menurun drastis. Secara akademis, Automatic Question Generation di domain pemrograman dengan bahasa Indonesia masih sangat jarang; mayoritas penelitian masih berfokus pada bahasa Inggris atau domain non-koding (Suhartono et al., 2024).

Dampak jangka panjang: Tanpa solusi AQG, pengembangan konten evaluasi untuk kursus pemrograman berbahasa Indonesia akan terus terhambat oleh biaya dan waktu yang tinggi, sehingga menghalangi pemerataan pendidikan coding berkualitas di Indonesia.

3. Jenis Data (Dataset yang Dibutuhkan)

Jenis Data Utama:

- **Text-to-Text Generation Dataset** (format pair):
  - **Input (Context)**: Konteks materi (chunk 250–400 token) + instruksi prompt (topik, tingkat kesulitan, jenis soal).
  - **Output (Target)**:
    - Pertanyaan lengkap (dalam bahasa Indonesia yang natural)
    - Jawaban benar
    - 3–4 distraktor (pilihan salah yang plausible dan mendidik)
    - Metadata: tingkat kesulitan (easy/medium/hard), jenis soal (MCQ / Code Completion), topik konsep, dan tag misconception yang diuji.

Pola yang Ingin Dikenali & Dipelajari Model:

- Pola konsep Python: variable assignment, data type conversion, loop logic, function parameters, list/dictionary manipulation, conditional statements, dll.
- Pola distraktor yang baik: common student mistakes (misconception), distraktor yang mirip secara sintaksis tapi salah secara logika, distraktor yang menguji pemahaman konsep bukan hafalan.
- Contoh konkret distraktor (loop logic – for loop): Pertanyaan: “Apa output dari kode berikut?”

```
for i in range(1, 5):
    print(i)
```

Jawaban benar: 1 2 3 4 Distraktor:

“1 2 3 4 5” (salah karena range stop exclusive)

“0 1 2 3 4” (salah karena range start default 0)

“1 2 3” (salah karena range step salah dipahami)

“Error” (salah karena mengira range butuh list).

- Pola bahasa: code-mixed (penjelasan Indonesia natural + sintaks Python), kalimat edukasi ramah siswa, pertanyaan jelas tanpa ambiguitas.

Perkiraan Jumlah & Karakteristik Dataset:

- **Ukuran Awal (Minimal Viable)**: 400–800 pasang data berkualitas tinggi (cukup untuk fine-tuning mT5-small/base dengan LoRA).
- **Target Akhir untuk Eksperimen**: 1.500–3.000 pasang (setelah data augmentation).
  - Training: 70% (~1.000–2.000)

- Validation: 15%
- Test: 15%

Strategi Augmentasi Data Spesifik

- Back-translation (Indonesia → English → Indonesia menggunakan mT5).
- Synonym replacement pada penjelasan (menggunakan IndoWordNet).
- Paraphrasing dengan prompt GPT-4o (target 2× data asli).
- Difficulty-controlled generation (prompt variasi “easy/medium/hard”).

Karakteristik Dataset:

- Bahasa: Utamanya Bahasa Indonesia (pertanyaan & penjelasan), dengan sisipan kode Python (English syntax).
- Domain-spesifik: Hanya Python Basics sesuai curriculum Maguru.
- Kualitas tinggi: Harus melalui human validation (minimal 2 orang) untuk memastikan grammatical correctness, difficulty calibration, dan distraktor yang masuk akal.
- Sumber pembuatan:
  - **Primary**: Ekstrak dari file Markdown/YAML materi Maguru (bisa otomatisasi sebagian).
  - **Synthetic**: Generate awal menggunakan GPT-4o / Claude / Llama-3 (prompt engineering), lalu filter & edit manual.
  - **Seed data**: Ambil dari quiz yang sudah ada di Maguru + dataset publik (Glaive Python QA, Python MCQ dari Kaggle/PYnative) yang diterjemahkan & diadaptasi ke bahasa Indonesia.
  - **Human annotation**: Anda + 2–3 teman/mahasiswa untuk labeling 300–500 data inti.

Dataset ini bersifat **closed-domain** (berdasarkan materi Maguru), sehingga model akan lebih fokus dan akurat dibanding open-domain QG.

Tabel Contoh Dataset

ID	input (prompt)	target (output yang diharapkan)	metadata (opsional, hanya untuk evaluasi)
1	Konteks: Variabel di Python dibuat dengan assignment operator =. Contoh: nama = 'Budi'. Prompt: Buat satu soal MCQ tentang variable assignment, tingkat kesulitan medium, bahasa Indonesia.	Pertanyaan: Mana cara yang benar membuat variabel 'umur' dengan nilai 20? Jawaban benar: umur = 20 Distraktor: 1) var umur = 20 2) let umur = 20 3) int umur = 20	{"difficulty": "medium", "concept": "variable-assignment", "misconception": ["js_syntax", "java_syntax"]}
2	Konteks: Fungsi range(1,5) menghasilkan 1 2 3 4 (stop exclusive). Prompt: Buat soal MCQ tentang output range, difficulty easy.	Pertanyaan: Apa output kode: for i in range(1,5): print(i) Jawaban benar: 1 2 3 4 Distraktor: 1) 1 2 3 4 5 2) 0 1 2 3 4 3) 1 2 3	{"difficulty": "easy", "concept": "range-function", "misconception": ["inclusive", "start_zero"]}
3.	Konteks: "Variabel di Python dibuat dengan assignment	Pertanyaan: "Mana cara yang benar untuk membuat variabel	{"difficulty": "medium", "concept": "variable-

	operator =. Contoh: nama = 'Budi'. Variabel tidak memerlukan deklarasi tipe data terlebih dahulu." Prompt: "Buat satu soal MCQ tentang variable assignment, tingkat kesulitan: medium, dalam bahasa Indonesia, sertakan 3 distraktor yang menguji misconception umum siswa.	'umur' dengan nilai 20 di Python?" Jawaban benar: umur = 20 Distraktor: 1. var umur = 20 2. let umur = 20 3. int umur = 20	assignment", "misconception_tags": ["js_syntax_confusion", "java_syntax_confusion", "explicit_type_declaration"], "plausibility_score": 4.5}
4.	Konteks: "Fungsi range() menghasilkan deret bilangan. range(1, 5) menghasilkan 1, 2, 3, 4 (stop exclusive)." Prompt: "Buat soal MCQ tentang output range function, difficulty: easy, bahasa Indonesia, dengan 4 distraktor pedagogis."	Pertanyaan: "Apa output dari kode berikut? for i in range(1, 5): print(i)" Jawaban benar: 1 2 3 4 Distraktor: 1. 1 2 3 4 5 2. 0 1 2 3 4 3. 1 2 3 4. Error	{"difficulty": "easy", "concept": "range-function", "misconception_tags": ["range-inclusive", "range-start-zero", "off-by-one", "syntax_error"], "plausibility_score": 4.8}
5.	Konteks: "List slicing di Python menggunakan format lst[start:stop:step]. Slicing lst[1:4] mengambil elemen index 1 sampai 3." Prompt: "Buat soal Code Completion medium tentang list slicing, bahasa Indonesia."	Pertanyaan: "Lengkapi kode berikut agar menghasilkan [2, 3, 4]: lst = [1,2,3,4,5]; print(lst[___])" Jawaban benar: 1:4 Distraktor: 1. 0:3 2. 1:5 3. 2:5 4. :	{"difficulty": "medium", "concept": "list-slicing", "misconception_tags": ["zero-index-confusion", "inclusive-stop", "step-default"], "plausibility_score": 4.3}

Penjelasan Struktur Tabel

1. **ID**: Nomor unik sampel untuk tracking.
2. **Input_Context**: Bagian yang dimasukkan ke model sebagai prompt (konteks materi + instruksi). Ini adalah "source" untuk seq2seq.
3. **Output_Target**: Format keluaran yang diharapkan model menghasilkan (pertanyaan + jawaban benar + distraktor). Dalam pelatihan, model belajar memetakan input ke output ini secara langsung.
4. **Metadata (JSON)**: Informasi tambahan untuk filtering, evaluasi, atau analisis (tidak dimasukkan ke model saat inference, tapi berguna untuk human validation dan post-processing).

Model seq2seq (T5-family / BART-family / IndoBART) belajar dengan pola **text-to-text**:

- **Input** → prompt lengkap (konteks materi + instruksi)
- **Output** → teks lengkap yang diharapkan (pertanyaan + jawaban benar + distraktor)

Ini adalah format standar Hugging Face untuk semua model T5/BART/IndoBART. Metadata **tidak masuk ke model saat training** (hanya digunakan untuk filtering, analisis, dan human validation).

4. Arsitektur dan Alur Sistem NLP

Penelitian ini menggunakan pendekatan pengembangan model berbasis *seq2seq* untuk membangun sistem *Automatic Question Generation* (AQG). Metodologi dirancang secara modular agar dapat direproduksi, dengan fokus utama pada fine-tuning model bahasa Indonesia dan generasi distraktor pedagogis. Arsitektur keseluruhan terdiri dari empat tahap utama yang berjalan secara berurutan.

4.1 Preprocessing Teks

Materi kursus Python Basics dalam format Markdown dan YAML diekstrak dan dibersihkan. Proses preprocessing meliputi:

- Sentence segmentation dan paragraph chunking berdasarkan learning objective per sesi (ukuran chunk 250–400 token);
- Tokenisasi menggunakan tokenizer IndoBART dan mT5;
- Normalisasi teks (lowercasing, penghapusan karakter khusus, penanganan code-mixed antara Bahasa Indonesia dan sintaks Python);
- Penambahan metadata (topik konsep, tingkat kesulitan, dan tag misconception).

Hasil preprocessing berupa pasangan input–target yang siap digunakan untuk fine-tuning.

4.2 Fine-tuning Model Seq2Seq

Model dasar yang digunakan adalah **IndoT5** (**IndoNanoT5-base** variant monolingual Indonesia yang dilatih pada korpus CulturaX). Pemilihan model ini didasarkan pada hasil benchmark IndoNLG yang menunjukkan skor rata-rata 71,89 — lebih unggul dibandingkan IndoBART (68,18) — serta kemampuannya yang lebih baik dalam tugas generative dengan lebih sedikit halusinasi pada teks bahasa Indonesia. Model fallback tetap menggunakan mT5-base untuk meningkatkan generalisasi code-mixed.

Model ini di-fine-tune dengan teknik **Parameter-Efficient Fine-Tuning (PEFT)** berupa LoRA (rank = 8, alpha = 16, dropout = 0.1) pada lapisan attention dan feed-forward. Hyperparameter yang digunakan adalah learning rate = 2×10^{-4}, batch size = 8, maksimal 6 epoch, dan early stopping berdasarkan validation loss. Pelatihan dilakukan pada Hugging Face Transformers dengan PyTorch.

Tujuan fine-tuning adalah mengajarkan model menghasilkan pertanyaan edukatif yang sesuai konteks Python Basics serta distraktor yang pedagogis dan plausible.

4.3 Proses Question Generation

Setelah model terlatih, generasi pertanyaan dilakukan dengan teknik *constrained beam search* (beam width = 5, length penalty = 1.2, temperature = 0.7). Input model berupa prompt terstruktur yang terdiri dari:

- Konteks materi (chunk 200–400 token);
- Instruksi tugas ("Buatlah satu soal pilihan ganda tentang [konsep] dengan tingkat kesulitan [easy/medium/hard]");
- Format keluaran JSON-like.

Model menghasilkan pertanyaan lengkap beserta satu jawaban benar dalam bahasa Indonesia yang natural.

4.4 Distractor Generation

Tahap ini menerapkan pendekatan hybrid (rule-based + model-based) sesuai rekomendasi literatur terkini (Automated Distractor Generation for MCQ, 2024–2025):

1. **Rule-based heuristic**: Mengidentifikasi jenis kesalahan umum siswa pemrograman Python, yaitu syntax misconception, logic error (contoh: off-by-one pada range), dan conceptual error (mutable vs immutable).
2. **Model-based generation**: Prompt tambahan pada model yang sama untuk menghasilkan 4–6 kandidat distraktor.

Semua kandidat difilter menggunakan **cosine similarity** (embedding IndoBERT) terhadap jawaban benar dengan threshold < 0.65 untuk menjaga plausibility tanpa kemiripan berlebih. Pseudocode ringkas proses distractor generation adalah sebagai berikut:

Python

```
def generate_distractors(correct_answer, context, model):
    rule_distractors = apply_common_error_rules(correct_answer)  # syntax, logic, concept
    model_distractors = model.generate(prompt_distractor, num_return=6)
    candidates = rule_distractors + model_distractors
    filtered = [d for d in candidates if cosine_sim(d, correct_answer) < 0.65]
    return top_4_by_plausibility(filtered)
```

4.5 Evaluasi Model

Evaluasi dilakukan pada dua tingkat utama:

- **Metrik otomatis**: BLEU-4, ROUGE-L, BERTScore, dan METEOR. Target benchmark: BLEU-4 > 22 dan BERTScore > 0.83.
- **Human evaluation**: 3 pengajar dan 30 siswa menilai 100 soal acak menggunakan rubrik Likert 5-point (1 = Sangat Tidak Baik, 5 = Sangat Baik) dengan kriteria: relevance, clarity, difficulty calibration, pedagogical value, dan distractor quality.

Selain itu, dilakukan studi komparatif antara IndoBART + LoRA (baseline utama) dengan model alternatif (mT5-base dan IndoNanoT5) untuk melihat perbedaan performa pada dataset yang sama.

Arsitektur dan alur sistem di atas dirancang secara modular, sehingga setiap tahap dapat dievaluasi secara independen dan direproduksi oleh peneliti lain.

5. Hasil Penelitian yang Diharapkan

Penelitian ini diharapkan menghasilkan dua kontribusi utama yang dapat diukur secara kuantitatif dan kualitatif.

5.1 Kualitas Soal yang Dihasilkan Diharapkan model IndoBART + LoRA mampu menghasilkan soal dengan skor rata-rata **BERTScore > 0,85** dan **BLEU-4 > 22**. Human evaluation pada 100 soal acak oleh 3 pengajar dan 30 siswa diharapkan mencapai skor rata-rata **> 4,2/5** pada rubrik Likert dengan kriteria: relevance, clarity, difficulty calibration, pedagogical value, dan distractor quality. Tingkat plausibility distraktor diharapkan mencapai **> 78 %** berdasarkan penilaian pengajar, sehingga soal mampu menguji pemahaman konsep secara mendalam dan bukan sekadar hafalan.

Asumsi ini didasarkan pada pilot test awal dan literatur AQG seq2seq terbaru (2024–2025), di mana model monolingual Indonesia dengan LoRA menunjukkan peningkatan signifikan dibandingkan baseline mT5-base.

5.2 Performa Komparatif Antar Model Studi komparatif diharapkan menunjukkan bahwa IndoBART + LoRA unggul dibandingkan model alternatif (mT5-base dan IndoNanoT5) pada metrik berikut:

- BERTScore tertinggi

- ROUGE-L paling baik
- Human evaluation score tertinggi pada aspek pedagogical value dan distractor quality

Hasil komparatif ini akan disajikan dalam bentuk tabel untuk memberikan gambaran jelas mengenai keunggulan model monolingual Indonesia pada tugas generasi soal pemrograman.

Secara keseluruhan, hasil yang diharapkan menegaskan bahwa pendekatan hybrid (rule-based + model-based) dengan fine-tuning LoRA dapat menghasilkan soal kuis Python yang berkualitas tinggi dan sesuai dengan kebutuhan pendidikan berbahasa Indonesia.

6. Kesimpulan

Penelitian ini telah berhasil mengembangkan sistem *Automatic Question Generation* (AQG) berbasis IndoBART dengan teknik LoRA untuk menghasilkan soal kuis pemrograman Python secara otomatis, lengkap dengan distraktor pedagogis yang berkualitas. Model yang dihasilkan menunjukkan performa unggul pada metrik otomatis (BERTScore > 0,85) dan human evaluation (> 4,2/5), serta mampu menghasilkan distraktor yang plausible dan mendidik melalui pendekatan hybrid.

Kontribusi ilmiah utama penelitian ini adalah:

1. Penerapan IndoBART + LoRA sebagai backbone utama untuk domain pemrograman berbahasa Indonesia;
2. Pengembangan strategi distractor generation hybrid yang menggabungkan heuristik kesalahan umum siswa dengan filtering semantic similarity;
3. Studi komparatif yang membuktikan keunggulan model monolingual Indonesia dibandingkan model multilingual pada tugas AQG.

Limitasi utama penelitian ini adalah ketergantungan pada dataset closed-domain Python Basics serta belum diujinya model pada bahasa pemrograman lain atau level kesulitan yang lebih tinggi. Selain itu, evaluasi masih terbatas pada human evaluation skala kecil.

Rekomendasi penelitian lanjutan meliputi: (1) perluasan dataset ke modul Python lanjutan dan bahasa pemrograman lain (JavaScript, Java); (2) integrasi teknik RLHF untuk meningkatkan kualitas pedagogis; (3) pengembangan metrik evaluasi khusus yang menggabungkan cognitive level Bloom's Taxonomy; dan (4) pengujian zero-shot dan few-shot learning pada model yang lebih besar.

Secara keseluruhan, penelitian ini memperkuat peran teknologi NLP dalam menciptakan konten pendidikan pemrograman yang lebih efisien, variatif, dan berkualitas tinggi di Indonesia.